卡尔曼滤波

第一部分：引例

引例一： 汽车的行程 z

（可能不准）

$$\begin{cases} \text{估计：} z = 100\ km/h \times 1h = 100\ km \\ \text{导航：} z_2 = 110\ km \quad (\text{better}) \end{cases}$$

最理想的行程可能为 $z_{best} = 0.1 z_1 + 0.9 z_2 = 109\ km$

$$\begin{cases} \text{估计：} z_1 = 10\ km/h \times 5s = 13.89\ m \quad (\text{better}) \\ \text{导航：} z_2 = 5\ m \quad (\text{短距离导航不准}) \end{cases}$$

最理想的行程可能为 $z_{best} = 0.8 z_1 + 0.2 z_2 = 12.11\ m$

引例二： 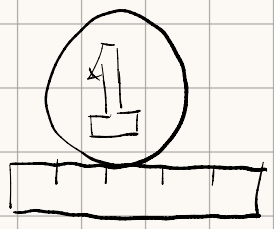 测量硬币的半径.

最优值显然为 $r_{best} = \hat{r}_n = \frac{1}{n}(r_1 + r_2 + \cdots + r_n)$ 取 n 个数据

变换 $\Rightarrow$ $= \frac{1}{n}(r_1 + r_2 + \cdots + r_{n-1}) + \frac{1}{n} r_n$

$= \frac{1}{n} \frac{n-1}{n-1}(r_1 + r_2 + \cdots + r_{n-1}) + \frac{1}{n} r_n$

$= \frac{n-1}{n} \hat{r}_{n-1} + \frac{1}{n} r_n$

$\Leftrightarrow \hat{r}_n = (1 - \frac{1}{n}) \hat{r}_{n-1} + \frac{1}{n} r_n$

$\Downarrow$ 更常用的形式

$\hat{r}_n = \hat{r}_{n-1} + \frac{1}{n}(r_n - \hat{r}_{n-1})$

不一定是前 $n-1$ 组的平均值与第 n 组数据融合，也可以是前 $n-m$ 组数据与后 m 组数据的融合

$\hat{r}_{n-1}$ 认为是一种估计方式

r_n 认为是另一种估计方式

$\hat{r}_n$ 认为是两种方式结果的融合

以上是从概率统计的角度对最优值的解释

思考：① 对于位置的状态量（如速度/距离/温度等）z，如果用两种方式估计得到 z_1, z_2

是否有 $\begin{cases} z_{best} = z_1 + k(z_2 - z_1) \\ \Updownarrow \end{cases}$ 其中 $k \in (0,1)$

$z_{best} = (1-k)z_1 + kz_2$

即 最优估计 = 估计值1 与 估计值2 的数据融合

② 在引例一中 估计值与导航值 相互独立.

在引例二中. 两个估计值 不相互独立.

对数据融合而言, 对两组数据 是否独立 无要求

但不相互独立的数据 融合 没有体现 数据融合的优势

相互独立的数据 融合才能发挥 数据融合的优势

在后续 均使用相互独立的数据

③ 如何寻找一个 k 使 z_{best} ($\hat{z}$) 最优?

第二部分. 数据融合

对于引例一 $\begin{cases} \text{估计} & z_1 = 100\,km \\ \text{导航} & z_2 = 110\,km \end{cases}$

$\hat{z} = z_1 + k(z_2 - z_1)$

如何找一个 k. 使 $\hat{z}$ 最优?

在概率统计中, 认为 z_1 与 z_2 是(可能)服从某种概率分布的统计量(如正态分布)

因此 $\hat{z}$ 也是一个统计变量 $\Rightarrow$ 有期望和方差

假设 $\sigma_1^2 = 8$

$\sigma_2^2 = 2$

找一个 k, 使 $\hat{z}$ 最优

找一个 k 使 $\hat{z}$ 方差最小 这是人为设定一个标准来标定 $\hat{z}$ 何时最优

$$\begin{aligned} Var(\hat{z}) &= Var[z_1 + k(z_2 - z_1)] \\ &= Var[(1-k)z_1] + Var(kz_2) \\ &= (1-k)^2\sigma_1^2 + k^2\sigma_2^2 \\ &= 8(1-k)^2 + 2k^2 \\ &= 10k^2 - 16k + 8 \end{aligned}$$

当 $k = 0.8$ 时 $Var(\hat{z})$ 取最小值.

此时 $\hat{z} = 108\,km$ $Var(\hat{z}) = 1.6$

这个方差小于 z_1 和 z_2 的

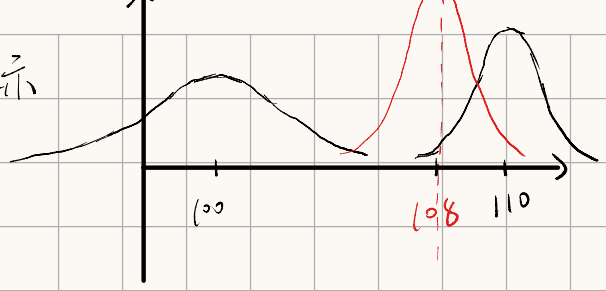

再图展示

为差，我们求的是最优

思考：回到这个式子 $\hat{z} = z_1 + K(z_2 - z_1)$

对于目标量 z，如果有 z_1 和 z_2 两种估计结果，我们就可以使用第二部分的思路求出 K，进一步求出最优 $\hat{z}$

那么对于任意状态量，我们怎么快速寻找两个相互独立的估计量？

第三部分：状态空间方程

$$\begin{cases} x_k = A x_{k-1} + B u_k + w_{k-1} \\ z_k = H x_k + v_k \end{cases}$$

x_k：当前状态；x_{k-1}：上一状态；u_k：外部输入；w_{k-1}：预测噪声 服从 $N(0, Q)$

A：某种变换；B：某种变换

z_k：观测值；H：某种变换；x_k：当前值；v_k：观测噪声 服从 $(0, R)$

以上是现代控制理论的状态空间方程，任意状态量的递推（线性）一方程

这两行公式的意义是：

从预测的角度：当前状态与三个因素有关，分别是上一状态、外部输入、预测噪声

从观测角度：当前状态与观测值和观测噪声有关

简单的例子，以引例一为例有：

$$\begin{cases} x_k = x_{k-1} + u\,\Delta t + w_{k-1} \\ z_k = x_k + v_{k-1} \end{cases}$$

x_k：当前路程；x_{k-1}：上一时刻路程；外部输入是时间 Δt

$A = 1$；$B = u$

$H = 1$

z_k：测量值：导航数据

其中 A B H 可以是矩阵形式，但例子不太好举

噪声是不可预测的，我们使用上面式做估计

$$\begin{cases} \hat{x}_k^- = A\hat{x}_{k-1} + Bu_k \\ z_k = H\hat{x}_{k\,mea} \end{cases} \Leftrightarrow \hat{x}_{k\,mea} = H^- z_k$$

得到两个估计值 $\hat{x}_k^-$ 与 $\hat{x}_{k\,mea}$.

利用 $\hat{z} = z_1 + K(z_k - z_1)$ 公式估计

$$\hat{x} = \hat{x}_k^- + K(\hat{x}_{k\,mea} - \hat{x}_k^-)$$

$$= \hat{x}_k^- + K(H^- z_k - \hat{x}_k^-)$$

可得上式 $K = K_k H$

$$\hat{x}_k = \hat{x}_k^- + K_k(z_k - H\hat{x}_k^-)$$

第四部分，正式进入卡尔曼滤波推导

$$\hat{x}_k = \hat{x}_k^- + \underset{n\times m}{K_k}\left(\underset{m\times 1}{z_k} - \underset{m\times n}{H}\underset{n\times 1}{\hat{x}_k^-}\right)$$

寻找 K_k 使 $\hat{x}_k$ 最优 这里最优的标准不是 x_k 的方差最小，因为无法计算，也无法得到普遍规律

采用新的评判 $\hat{x}_k$ 最优的方法

令 $e_k = x_k - \hat{x}_k$ 注意 x_k 是真实值

求 e_k 方差最小的情况 (在数学上定义为协方差矩阵的迹的大小)

求 e_k 的协方差矩阵 P (之前也提到了两个协方差矩阵，分别是预测噪声 w_{k-1} 的协方差 Q，观测噪声的协方差矩阵 R.)

引入数学公式

$$Cov(X) = E\left[(X-u)(X-u)^T\right]$$

x_k 为均值，如果 $u=0$，则 $cov(x)=E(xx^T)$

e_k 为真实值与最优估计的差，最优估计中包含过程噪声与测量噪声的加权融合，因此总体误差 e_k 保留了 w_{k-1} 和 v_k 的特征，服从均值为0的正态分布（w_{k-1} 和 v_k 相互独立）

定量运算处理 $E(e_k)=0$ 有点困难

$$
\begin{aligned}
e_k &= x_k - \hat{x}_k \\
&= x_k - (\hat{x}_k^- + K_k(z_k - H\hat{x}_k^-)) \\
&= x_k - \hat{x}_k^- - K_k z_k + K_k H \hat{x}_k^- \\
&= x_k - \hat{x}_k^- - K_k H x_k - K_k v_k + K_k H \hat{x}_k^- \\
&= (I - K_k H)(x_k - \hat{x}_k^-) - K_k v_k \\
&= (I - K_k H)\, e_k^- - K_k v_k
\end{aligned}
$$

$$
\begin{aligned}
P &= E(e_k e_k^T) \\
&= E\{[(I-K_kH)e_k^- - K_k v_k][(I-K_kH)e_k^- - K_k v_k]^T\} \\
&\qquad \downarrow \quad [e_k^{-T}(I-K_kH)^T - v_k^T K_k^T] \\
&= E[(I-K_kH)e_k^- e_k^{-T}(I-K_kH)^T] - E[(I-K_kH)e_k^- v_k^T K_k^T] \\
&\quad - E(K_k v_k e_k^{-T}(I-K_kH)^T) + E(K_k v_k v_k^T K_k^T) \\
&\qquad \text{常量} \quad E(v_k)=0 \quad \text{常量} \\
&= E[(I-K_kH)e_k^- e_k^{-T}(I-K_kH)^T] - 0 - 0 + E(K_k v_k v_k^T K_k^T) \\
&= (I-K_kH)\,E(e_k^- e_k^{-T})\,(I-K_kH)^T + K_k E(v_k v_k^T) K_k^T \\
&\qquad \text{常量} \quad \text{令其为 } P_k^- \quad \text{常量} \qquad v_k \text{ 服从正态分布，均值为0，并协方差矩阵 } R = E(v_k v_k^T) \\
&= (I-K_kH)\,P_k^-\,(I-K_kH)^T + K_k R K_k^T \\
&\qquad (I - H^T K_k^T)
\end{aligned}
$$

$$P_k = P_k^- - P_k^- H^T K_k^T - K_k H P_k^- + K_k H P_k^- H^T K_k^T + K_k R K_k^T$$

目标：求当 K_k 为何值时，协方差矩阵的迹最小

先求迹 $tr(P_k)$ → 对 K_k 求导 → 令导数 $\frac{d\,tr(P_k)}{dK_k} = 0$

$$tr(P_k) = tr(P_k^-) - tr(P_k^- H^T K_k^T) - tr(K_k H P_k^-) + tr(K_k H P_k^- H^T K_k^T) + tr(K_k R K_k^T)$$

引入数学定理 $\frac{d\,tr(AB)}{dA} = B^T$

设 AB 为 $n \times n$ 矩阵，则 $AB_{ij} = \sum_{k=1}^{n} A_{ik} B_{kj}$

$$tr(AB) = \sum_{i=1}^{n} \sum_{j=1}^{n} A_{ij} B_{ji}$$，求 $\frac{d\,tr(AB)}{dA} = D$

$$D_{xy} = \frac{\partial\, tr(AB)}{\partial A_{xy}} = B_{yx}$$

$\therefore D = B^T$ 即 $\frac{d\,tr(AB)}{dA} = B^T$

$$tr(ABA^T) = \sum_{i=1}^{n} \sum_{j=1}^{n} \sum_{k=1}^{n} A_{ij} B_{jk} A^T_{ki}$$

$A^T_{ki} = A_{ik}$

求 $\frac{d\,tr(ABA^T)}{dA}$ ⇒

$$D_{xy} = \frac{\partial\, tr(ABA^T)}{\partial A_{xy}} = \sum_{k=1}^{n} B_{yk} A^T_{kx} + \sum_{j=1}^{n} A_{xj} B_{jy}$$

$$= (BA^T)_{yx} + (AB)_{xy}$$

$$= (AB^T)_{xy} + (AB)_{xy}$$

$\therefore D = AB^T + AB$

如果 B 是对称阵 $\frac{d\,tr(ABA^T)}{dA} = 2AB$

$tr(AB) = tr(BA)$

$$tr(P_k) = tr(P_k^-) - tr(P_k^- H^T K_k^T) - tr(K_k H P_k^-) + tr(K_k H P_k^- H^T K_k^T)$$

这两个式子相同

$$+ tr(K_k R K_k^T)$$

$$\frac{d\,tr(P_k)}{d K_k} = 0 - 2\frac{d\,tr(K_k H P_k^-)}{d K_k} + 2K_k H P_k^- H^T + 2K_k R$$

$(H P_k^-)^T$

令 $\frac{d\,tr(P_k)}{d K_k} = 0$ 求极小值

得 $P_k^- H^T = K_k (H P_k^- H^T + R)$

Kalman Gain 卡尔曼增益

$$K_k = \frac{P_k^- H^T}{H P_k^- H^T + R}$$ → 观测噪声的协方差矩阵

反应的是过程噪声的影响程度

当观测噪声的影响更大，$K_k \to 0$，更相信预测值

当过程噪声的影响更大，$K_k \to H^-$，更相信观测值

如何求 P_k^- 那如何求 $\hat{e}_k^-$ 的协方差矩阵

$$\text{令 } \hat{e}_k^- = x_k - \hat{x}_k^-$$

$$x_k = A x_{k-1} + B u_k + w_{k-1}$$

$$\hat{x}_k^- = A \hat{x}_{k-1} + B u_k$$

$$x_k - \hat{x}_k^- = A(x_{k-1} - \hat{x}_{k-1}) + w_{k-1}$$

$$= A e_{k-1} + w_{k-1}$$

$$\hat{e}_k^- = A(x_{k-1} - \hat{x}_{k-1}) + w_{k-1}$$

$$P_k^- = E(\hat{e}_k^- \hat{e}_k^{-T})$$

$$= E[(A e_{k-1} + w_{k-1})(A e_{k-1} + w_{k-1})^T]$$

$$= E[(A e_{k-1} + w_{k-1})(e_{k-1}^T A^T + w_{k-1}^T)]$$

$$= E(A e_{k-1} e_{k-1}^T A^T + A e_{k-1} w_{k-1}^T + w_{k-1} e_{k-1}^T A^T + w_{k-1} w_{k-1}^T)$$

易证这两项的期望为0

$$= E(A e_{k-1} e_{k-1}^T A^T) + \cdots$$

$$= E(Ae_{k-1}e_{k-1}^T A^T) + E(w_{k-1}w_{k-1}^T)$$

$$= A\,E(e_{k-1}e_{k-1}^T)A^T + E(w_{k-1}w_{k-1}^T)$$

$P_k^- = A P_{k-1} A^T + Q$ → Q是过程噪声w的协方差矩阵

这里说明 P_k^- 是能反映过程噪声大小的

求 P_k^- 需要用到 P_{k-1} 是否应该求 P_k 为 P_{k+1} 的计算做准备？

$P_k = P_k^- - P_k^- H^T K_k^T - K_k H P_k^- + K_k H P_k^- H^T K_k^T + K_k R K_k^T$ （之前已经推了）

$= P_k^- - P_k^- H^T K_k^T - K_k H P_k^- + K_k (H P_k^- H^T + R) K_k^T$

↓代入

$= P_k^- - P_k^- H^T K_k^T - K_k H P_k^- + \frac{P_k^- H^T}{H P_k^- H^T + R} (H P_k^- H^T + R) K_k^T$

$= P_k^- - P_k^- H^T K_k^T - K_k H P_k^- + P_k^- H^T K_k^T$

$= P_k^- - K_k H P_k^-$

$= (I - K_k H) P_k^-$

卡尔曼滤波步骤

① $\hat{X}_k^- = A\hat{X}_{k-1} + Bu_k$

② $P_k^- = A P_{k-1} A^T + Q$

③ $K_k = \frac{P_k^- H^T}{H P_k^- H^T + R}$

④ $\hat{X}_k = \hat{X}_k^- + K_k (Z_k - H\hat{X}_k^-)$

⑤ $P_k = (I - K_k H) P_k^-$

数据融合 → 怎样求合适的 K？→ 方差最小

怎样获得任意变量的两个相互独立的估计值 → 状态空间方程

寻找 Kalman Gain? → $e_k = x_k - \hat{x}_k$ 求 e_k 的方差最小时 K_k 的值

→ 即求 e_k 的协方差矩阵 P 的迹 $tr(P)$ 最小时 K_k 的值

→ 求 $tr(P)$，求导，令导数等于 0 得到 Kalman Gain

扩展卡尔曼滤波

非线性系统 $x_k = f(x_{k-1}, u_{k-1}, w_{k-1})$ $w \sim N(0, Q)$

$z_k = h(x_k, v_k)$ $v \sim N(0, R)$

正态分布经过非线性映射就不再正态

非线性系统线性化

泰勒展开 $f(x) = f(x_0) + \frac{df}{dx}(x - x_0)$ 对于多元函数，如 $X = \begin{bmatrix} x_0 \\ x_1 \\ x_2 \end{bmatrix}$ 需要求雅可比矩阵

多元泰勒展开 $f(x) = f(x_0) + A(x - x_0)$ 其中 $A = \begin{pmatrix} \frac{df_1}{dx_1} & \frac{df_1}{dx_2} & \frac{df_1}{dx_3} \\ \frac{df_2}{dx_1} & \frac{df_2}{dx_2} & \frac{df_2}{dx_3} \\ \frac{df_3}{dx_1} & \frac{df_3}{dx_2} & \frac{df_3}{dx_3} \end{pmatrix}$

↓ 在定点的线性化不准确

对 $x_k = f(x_{k-1}, u_{k-1}, w_{k-1})$ 的多元泰勒展开在 $\hat{x}_{k-1}$ 处 ($k-1$ 时刻的最优估计)

为了便于估计，假设误差为 0

$x_k = f(\hat{x}_{k-1}, u_{k-1}, w_{k-1}) + A(x_{k-1} - \hat{x}_{k-1}) + w * w_{k-1}$ 其中 $A = \frac{df}{dx}\Big|_{\hat{x}_{k-1}, u_{k-1}}$

$$\begin{pmatrix} \frac{df_1}{dx_1} & \frac{df_1}{dx_2} & \cdots & \frac{df_1}{dx_n} \\ \frac{df_2}{dx_1} & \frac{df_2}{dx_2} & \cdots & \frac{df_2}{dx_n} \\ \vdots & \vdots & & \vdots \\ \frac{df_n}{dx_1} & \frac{df_n}{dx_2} & \cdots & \frac{df_n}{dx_n} \end{pmatrix}$$

$W = \frac{df}{dw}\Big|_{\hat{x}_{k-1}, u_{k-1}}$

令 $\tilde{x}_k = f(\hat{x}_{k-1}, u_{k-1}, 0)$

z_k 在 $\tilde{x}_k$ 处展开

$z_k = h(\tilde{x}_k, v_k) + H(x_k - \tilde{x}_k) + V * v_k$ （v_k 令其为 0）

$H = \frac{dh}{dx}\Big|_{\tilde{x}_k}$ $V = \frac{dh}{dv}\Big|_{\tilde{x}_k}$

$z_k = \tilde{z}_k + H(x_k - \tilde{x}_k) + V * v_k$

总结 $\begin{cases} x_k = \tilde{x}_k + A(x_{k-1} - \hat{x}_{k-1}) + W * w_{k-1} \\ z_k = \tilde{z}_k + H(x_k - \tilde{x}_k) + V * v_k \end{cases}$ ← 协方差

$W * w_{k-1} \sim N(0, WQW^T)$

$V * v_k \sim N(0, VRV^T)$

EKF 的流程

$\tilde{x}_k = f(\hat{x}_{k-1}, u_{k-1}, 0)$

$P_k^- = AP_{k-1}A^T + WQW^T$

$K_k = \frac{P_k^- H^T}{H P_k^- H^T + VRV^T}$

$\hat{x}_k = \tilde{x}_k^- + K_k(z_k - h(\tilde{x}_k^-, 0))$

$P_k = (I - K_k H) P_k^-$

补充

状态空间的表达：弹簧振动阻尼系统

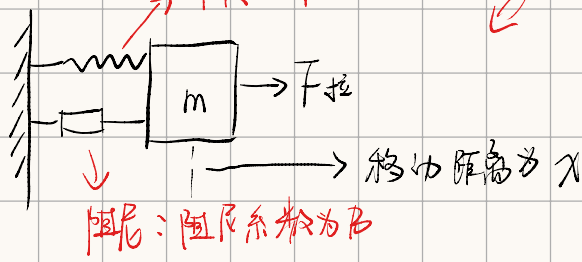

（另外，物体有在对 距离和速度 的影响）

$F_合 = ma$

$F_{拉} - Kx - Bv = ma$

$F_{拉} = kx + Bv + ma$ 可移上写成 $F = kx + B\dot{x} + m\ddot{x}$ ← 分别是1阶2阶导

→ 可移上令 $F = u$，即外部输入

$F = kx + B\dot{x} + m\ddot{x}$

令 $x_1 = x$ 距离

$x_2 = \dot{x}$ 速度

求 $\dot{x}_1$ 和 $\dot{x}_2$

$$\begin{cases} \dot{x}_1 = x_2 \\ \dot{x}_2 = \ddot{x} = \frac{1}{m}u - \frac{1}{m}Kx - \frac{1}{m}B\dot{x} \end{cases}$$

(x_1, x_2)

$$\begin{cases} \dot{x}_1 = x_1 \\ \dot{x}_2 = \frac{1}{m}u - \frac{1}{m}Kx_1 - \frac{1}{m}Bx_2 \end{cases} \Rightarrow \begin{bmatrix} \dot{x}_1 \\ \dot{x}_2 \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ -\frac{K}{m} & -\frac{B}{m} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + \begin{bmatrix} 0 \\ \frac{1}{m} \end{bmatrix} u$$

$$\dot{X}(t) = A \quad X(t) + B \quad ut$$

对上式做离散化处理

$$X(t) = X(t-1) + \dot{X}(t-1)\,dt$$

$$\downarrow$$

$$(A\,X(t-1) + B\,ut-1)\,dt$$

$$= (I + A\,dt)\,X(t-1) + B\,dt\;ut-1$$

令 $A = I + A\,dt$

$B = B\,dt$

$$X(t) = A\,X(t-1) + B\,ut-1$$

新的A　　新的B

即 $X_k = A\,X_{k-1} + B\,u_{k-1} + W_{k-1}$　　式①

另外，还存在观测量 $\begin{cases} z_1 = x_1 \\ z_2 = x_2 \end{cases}$

$$\begin{bmatrix} z_1 \\ z_2 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + V_k$$

$$\downarrow$$

$$z_k = H\,x_k + V_k$$

式②

联结式①式②，得到方程

$$\begin{cases} X_k = A\,X_{k-1} + B\,u_{k-1} + W_{k-1} \\ z_k = H\,x_k + V_k \end{cases}$$

发现其后线性状态量也服从这个式子，得其总结为状态空间方程

为什么不以 x_k 误差最小为标准，而是以 $e = x_k - \hat{x}_k$ 误差最小

补充：

$$\hat{x}_k = \hat{x}_k^- + K_k(z_k - H\hat{x}_k^-)$$

求 $\mathrm{var}(\hat{x}_{k|k}) = P = E[(\hat{x}_{k|k}-u)(\hat{x}_{k|k}-u)^T]$

↳ u 未知，应先求 $u = E(\hat{x}_{k|k})$

$E(\hat{x}_{k|k}) = E[(I-K_kH)\hat{x}_{k|k} + K_k z_k]$

$= (I-K_kH)\,E(\hat{x}_{k|k}) + K_k\,E(z_k)$

$K_kH\,E(x_{k|k})$

$$\begin{cases} \hat{x}_{k|k} = A\hat{x}_{k-1} + Bu_{k-1} \\ z_k = H x_{k\,mea} \end{cases}$$

$E(A\hat{x}_{k-1} + Bu_{k-1})$

$= A\,E(\hat{x}_{k-1}) + B u_{k-1}$

↳ 可以迭代

↳ 外部输入是未知的，不可预测的。如弹簧振动阻尼系统中的干扰不是一个随机变量，无均值

$= (I-K_kH)[A\,E(\hat{x}_{k-1}) + Bu_{k-1}] + K_kH\,E(x_{k|k})$

$= (I-K_kH)A\,E(\hat{x}_{k-1}) + (I-K_kH)B u_{k-1} + K_kH\,E(x_k)$

x_k 是 $n\times 1$ 向量　z_k 是 $m\times 1$　H 是 $m\times n$　K_k 是 $n\times m$　Bu_k 是 $n\times 1$

$$\mathrm{Var}(\hat{x}_{k|k}) = P = E\Big\{[\hat{x}_{k|k} - (I-K_kH)AE(\hat{x}_{k-1}) - (I-K_kH)Bu_{k-1} - K_kHE(x_{k|k})]$$

$$[\hat{x}_{k|k}^T - E^T(\hat{x}_{k-1})A^T(I-K_kH)^T - u_{k-1}^T B^T (I-K_kH)^T - E^T(x_{k|k})H^T K_k^T]\Big\}$$

展开后为 6 项和的期望

$$P = E\Big[\underset{n\times 1\ \ 1\times n}{\hat{x}_k\hat{x}_{k|k}^T} - \underset{n\times 1\ \ 1\times n}{\hat{x}_{k|k}E^T(\hat{x}_{k-1})}\underset{n\times n}{A^T}\underset{n\times n}{(I-K_kH)^T} - \underset{n\times 1\ \ 1\times n}{\hat{x}_{k|k}u_{k-1}^T}\underset{n\times n}{B^T}\underset{n\times n}{(I-K_kH)^T} - \underset{n\times 1\ \ 1\times n}{\hat{x}_{k|k}E^T(x_{k|k})}\underset{n\times m}{H^T}\underset{m\times n}{K_k^T}$$

$$-(I-K_kH)AE(\hat{x}_{k-1})\hat{x}_{k|k}^T + (I-K_kH)AE(\hat{x}_{k-1})E^T(\hat{x}_{k-1})A^T(I-K_kH)^T + (I-K_kH)AE(\hat{x}_{k-1})u_{k-1}^T B^T(I-K_kH)^T$$

$$+(I-K_kH)AE(\hat{x}_{k-1})E^T(x_{k|k})H^TK_k^T - (I-K_kH)Bu_{k-1}\hat{x}_{k|k}^T + (I-K_kH)Bu_{k-1}E^T(\hat{x}_{k-1})A^T(I-K_kH)^T$$

$$+(I-K_kH)Bu_{k-1}u_{k-1}^TB^T(I-K_kH) + (I-K_kH)Bu_{k-1}E^T(x_{k|k})H^TK_k^T - K_kHE(x_{k|k})\hat{x}_{k|k}^T$$

$$+K_kHE(x_{k|k})E^T(\hat{x}_{k-1})A^T(I-K_kH)^T + K_kHE(x_{k|k})u_{k-1}^TB^T(I-K_kH)^T + K_kHE(x_{k|k})E^T(x_{k|k})H^TK_k^T\Big]$$

转化为 6 项期望的和

$P = E[\hat{x}_k \hat{x}_k^T] + E[\dots] + \dots + E[\dots] + E[K_k H E[x_k] E^T[x_k] H^T K_k^T]$

接下来 求 $tr(P)$ → 求 $\frac{d\,tr(P)}{dK_k}$ → 令 $\frac{d\,tr(P)}{dK_k} = 0$ 得 K_k

$tr(P) = tr[E(\hat{x}_k \hat{x}_k^T)] + tr[E(\dots)] + \dots + tr[E(\dots)] + tr[E(K_k H E[x_k] E^T[x_k] H^T K_k^T)]$

$\frac{d\,tr(P)}{dK_k} = \dots$ ← 尝试求第1项对 K_k 的导数

$\frac{d\,tr[E(\hat{x}_k \hat{x}_k^T)]}{dK_k} = \frac{d\,tr\{E[(\hat{x}_k^- + K_k z_k - K_k H \hat{x}_k^-)][\hat{x}_k^{-T} + z_k^T K_k^T - \hat{x}_k^{-T} H^T K_k^T]\}}{dK_k}$

$E(\hat{x}_k \hat{x}_k^T) = E(\hat{x}_k^- \hat{x}_k^{-T} + \hat{x}_k^- z_k^T K_k^T + \hat{x}_k^- \hat{x}_k^{-T} H^T K_k^T$

太复杂了，不算了

跟据上面的式子来必能算出 K_k，从 K_k 的本质说起

本质上 $K = \frac{e_{est}}{e_{est} + e_{mea}}$

e_{est}：过程误差　e_{mea}：观测误差

$\hat{x} = (1-K)x_1 + Kx_2 = x_1 + K(x_2 - x_1)$

- 当 e_{est} 大于 e_{mea}，即过程误差大，观测误差小：$K \to 1$　$\hat{x} \to x_2$　更相信观测值
- 当 e_{est} 小于 e_{mea}　即过程误差小，观测误差大　$K \to 0$　$\hat{x} \to x_1$　更相信预测值

因此，只有引入误差 e，才可能算出 K_k

$P = var(\hat{x}_k) = (1-K)^2 var(\hat{x}_k^-) + K^2 var(x_{k\,mea})$　这里应该是矩阵、不严谨，但仅用于理解，就忽略这处不严谨的地方了

$= [var(\hat{x}_k^-) + var(x_{k\,mea})] K^2 - 2\,var(\hat{x}_k^-) K + 1$

当 $K = \frac{var(\hat{x}_k^-)}{var(\hat{x}_k^-) + var(x_{k\,mea})}$ → 观测值隐含 V_k

$var(\hat{x}_k^-)$：不含有 W_{k-1} 的信息

因此 $var(\hat{x}_k^-)$ 不含有 W_{k-1}，无法正确求出 K_k

引入 $e_k = x_k - \hat{x}_k^-$　求 $var(e_k)$

在第5页，我们将下面红色式子中的 z_k 代入为 $z_k = Hx_k + v_k$

存疑：在讲解时我们也提出是否可以代入 x_k 或 $\hat{x}_k$？

$$e_k = x_k - \hat{x}_k$$

$$= x_k - \left(\hat{x}_k^- + K_k(z_k - H\hat{x}_k^-)\right)$$

在这里我们尝试用 $\begin{cases} \hat{x}_k^- = A\hat{x}_{k-1} + Bu_{k-1} \\ x_k = Ax_{k-1} + Bu_{k-1} + w_{k-1} \\ z_k = Hx_k + v_k \end{cases}$ 同时代入

$$e_k = Ax_{k-1} + Bu_{k-1} + w_{k-1} - (A\hat{x}_{k-1} + Bu_{k-1}) - K_k(Hx_k + v_k - H\hat{x}_k^-)$$

$$= A(x_{k-1} - \hat{x}_{k-1}) + w_{k-1} - K_k H(x_k - \hat{x}_k^-) - K_k v_k$$

$$= Ae_{k-1} + w_{k-1} - K_k H e_k^- - K_k v_k$$

$$P_k = E(e_k e_k^T)$$

$$= E\Big[(Ae_{k-1} + w_{k-1} - K_k H e_k^- - K_k v_k)(e_{k-1}^T A^T + w_{k-1}^T - e_k^{-T} H^T K_k^T - v_k^T K_k^T)\Big]$$

$Ae_{k-1}w_{k-1}^T$ 的期望为0，就不写，后面有期望为0的也不写

$$= E\Big[Ae_{k-1}e_{k-1}^T A^T + \cdots - Ae_{k-1}e_k^{-T}H^T K_k^T - Ae_{k-1}v_k^T K_k^T$$

$$+ w_{k-1}w_{k-1}^T - w_{k-1}e_k^{-T}H^T K_k^T + \cdots - K_k H e_k^- e_{k-1}^T A^T$$

$$- K_k H e_k^- w_{k-1}^T + K_k H e_k^- e_k^{-T} H^T K_k^T + \cdots - K_k v_k e_{k-1}^T A^T$$

$$+ K_k v_k v_k^T K_k^T\Big]$$

此处省略一些步骤

$$P_k = APA^T + Q + K_k H P_k^- H^T K_k^T + K_k R K_k^T - AE(e_{k-1}e_k^{-T})H^T K_k^T$$

$$- AE(e_{k-1}v_k)K_k - E(w_{k-1}e_k^{-T})H^T K_k^T - K_k H E(e_k^- e_{k-1}^T)A^T$$

下面这个是我们用另一个方法得到的 P_k，是正确的 P_k

$$P_k = P_k^- + K_k H P_k^- H^T K_k^T + K_k R K_k^T - P_k^- H^T K_k^T - K_k H P_k^-$$

经过上面的知识我们知道上面两个式子黑色的部分相等

只要证明红色的部分也相等就可以证明另一种展开方式也能得到正确的 P_k

先求 $A E(e_{k-1} e_k^{-T}) H^T K_k^T$

$$e_{k-1} = x_{k-1} - \hat{x}_{k-1}$$

$$e_k^- = x_k - \hat{x}_k^-$$

$$= A x_{k-1} + B u_{k-1} + w_{k-1} - (A \hat{x}_{k-1} + B u_{k-1})$$

$$= A e_{k-1} + w_{k-1}$$

即 $e_k^- = A e_{k-1} + w_{k-1}$

$$e_k^- - w_{k-1} = A e_{k-1}$$

$$A^{-1}(e_k^- - w_{k-1}) = e_{k-1}$$

则 $A E(e_{k-1} e_k^{-T}) H^T K_k^T$

$$= A E[A^{-1}(e_k^- - w_{k-1}) e_k^{-T}] H^T K_k^T$$

$$= E[(e_k^- - w_{k-1}) e_k^{-T}] H^T K_k^T$$

$$= E(e_k^- e_k^{-T} - w_{k-1} e_k^{-T}) H^T K_k^T$$

$$= E(e_k^- e_k^{-T}) H^T K_k^T - E(w_{k-1} e_k^{-T}) H^T K_k^T$$

$$= P_k^- H^T K_k^T - E(w_{k-1} e_k^{-T}) H^T K_k^T$$

$P_k^- H^T K_k^T$ 发现这一项出现

$E(w_{k-1} e_k^{-T}) H^T K_k^T$ 后面正好有一项与这项抵消

于我们正确推导的 P_{k+1}

$K_k H E(e_k^- e_{k-1}^T) A^T$ 的求解同上

因此我们证明从第14次开始的展开方式同样能求出正确的 P_k

补充：扩展卡尔曼滤波

非线性系统 $\begin{cases} X_k = f(X_{k-1}, u_{k-1}, w_{k-1}) \\ Z_k = h(X_k, V_k) \end{cases}$

为了将非线性系统线性化 ⇒ 使用一阶泰勒展开。

一元函数的一阶展开 $f(x) = f(x_0) + f(x_1)(x - x_0)$

多元函数的泰勒展开 $X = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}$ $f(X) = \begin{bmatrix} f_1 \\ f_2 \\ f_3 \end{bmatrix}$

$f(X) = f(X_0) + J_X^f (X - X_0)$ 其中 $J_X^f = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \frac{\partial f_1}{\partial x_3} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \frac{\partial f_2}{\partial x_3} \\ \frac{\partial f_3}{\partial x_1} & \frac{\partial f_3}{\partial x_2} & \frac{\partial f_3}{\partial x_3} \end{bmatrix}$ 为雅可比矩阵

① 对 $X_k = f(X_{k-1}, u_{k-1}, w_{k-1})$ 做一阶泰勒展开

首先，确定在何点进行一阶展开？

要求展开点离 X_{k-1} 要近 → 选取 $\hat{X}_{k-1}$ 上一周期最优估计，已经算出来了，是已知的点，同时距离 X_{k-1} 很近。

$$X_k = f(\hat{X}_{k-1}, u_{k-1}, w_{k-1}) + J_{X_{k-1}}^f (X_{k-1} - \hat{X}_{k-1})$$

这个式子有什么问题？

对泰勒展开而言，$f(\hat{X}_{k-1}, u_{k-1}, w_{k-1})$ 应该是个数，

但这个式子中含有 w_{k-1}，算不出来，对工程而言是不好的

解决 → 主动地，强行将 $f(\hat{X}_{k-1}, u_{k-1}, w_{k-1})$ 变成 $f(\hat{X}_{k-1}, u_{k-1}, 0)$

结果 { 舍去 w_{k-1}，$f(\hat{X}_{k-1}, u_{k-1}, 0)$ 可以计算了。

w_{k-1} 为误差，将较小值舍去，在工程上不会有产大影响

原式变成：$X_k = f(\hat{X}_{k-1}, u_{k-1}, 0) + J_{X_{k-1}}^f (X_{k-1} - \hat{X}_{k-1})$

问题又出现了，整个式子中不含误差项了

将整个系统的误差看作 w'_{k-1}

原式变成：$X_k = f(\hat{X}_{k-1}, u_{k-1}, 0) + J_{X_{k-1}}^f (X_{k-1} - \hat{X}_{k-1}) + w'_{k-1}$

结束

在这里 $w_{k-1} = W \times w_{k-1}$

w'_{k-1} 是新误差，

w_{k-1} 是老误差

W 是 J_W^f 即 f 对 W 的偏导

为什么？→ 先不管，后面再说

② 对 $z_k = h(x_k, v_k)$ 做线性化

找一个离 x_k 近的点做线性化

在上面求了 $x_k = f(\hat{x}_{k-1}, u_{k-1}, 0) + \int_{x_{k-1}}^{t} (x_{k-1} - \hat{x}_{k-1}) + w'_{k-1}$

↓ 这是一个能算的数，且离 x_k 很近

未知，且是很小的值，舍去

↳ 为什么离 x_k 近？因为 $\hat{x}_{k-1}$ 离 x_{k-1} 近，我们在这个点做展开，常数项显然离 x_k 近

为了方便书写令 $\tilde{x}_k = f(\hat{x}_{k-1}, u_{k-1}, 0)$

$$z_k = h(\tilde{x}_k, v_k) + \int_{x_k}^{h} (x_k - \tilde{x}_k)$$

↳ $$z_k = h(\tilde{x}_k, 0) + \int_{x_k}^{h} (x_k - \tilde{x}_k) + v'_k$$

这一步的原因和上面一样

至此，完成线性化工作.

非线性系统 $\begin{cases} x_k = f(x_{k-1}, u_{k-1}, w_{k-1}) \\ z_k = h(x_k, v_k) \end{cases}$ 线性化 $\Rightarrow$ $\begin{cases} x_k = f(\hat{x}_{k-1}, u_{k-1}, 0) + \int_{x_{k-1}}^{t} (x_{k-1} - \hat{x}_{k-1}) + w'_{k-1} \\ z_k = h(\tilde{x}_k, 0) + \int_{x_k}^{h} (x_k - \tilde{x}_k) + v'_k \end{cases}$

线性定常的状态空间方程 $\begin{cases} x_k = Ax_{k-1} + Bu_{k-1} + w_{k-1} \\ z_k = Hx_k + v_k \end{cases}$

线性化后的状态空间方程 $\begin{cases} x_k = f(\hat{x}_{k-1}, u_{k-1}, 0) + \int_{x_{k-1}}^{t} (x_{k-1} - \hat{x}_{k-1}) + w'_{k-1} \\ z_k = h(\tilde{x}_k, 0) + \int_{x_k}^{h} (x_k - \tilde{x}_k) + v'_k \end{cases}$

在预测时，这一项显然为0，因为 x_k 的预测值就是 $\hat{x}_k$

↓

卡尔曼的方程 $\begin{cases} \hat{x}_k = A\hat{x}_{k-1} + Bu_{k-1} \\ z_k = Hx_{k,mea} \end{cases}$

卡尔曼 $\begin{cases} \hat{x}_k^- = f(\hat{x}_{k-1}, u_{k-1}, 0) \\ z_k = h(\hat{x}_k^-, 0) \end{cases}$

注意到 $\hat{x}_k^-$ 与 $\tilde{x}_k$ 在数值上相等

且 $z_k = h(\hat{x}_k^-, 0)$

在线性系统下：$\hat{x}_k = \hat{x}_k^- + K_k(z_k - H\hat{x}_k^-)$

这个像不像 $\hat{z}_k^-$ 在非线性系统中其实就是 $h(\hat{x}_k^-, 0)$

非线性

$$\hat{x}_k = \hat{x}_k^- + K_k[z_k - h(\hat{x}_k^-, 0)]$$

$$e_k = x_k - \hat{x}_k$$

$$= x_k - \hat{x}_k^- - K_k z_k + K_k h(\hat{x}_k^-, 0)$$

$$= e_k^- - K_k h(\hat{x}_k^-, 0) - K_k J_x^h (x_k - \hat{x}_k^-) - v_k + K_k h(\hat{x}_k^-, 0)$$

$$= (I - K_k J_x^h) e_k^- - v_k'$$

$$P_k = E(e_k e_k^T)$$

$$= E\left\{ [(I - K_k J_x^h) e_k^- - v_k'] [e_k^{-T} (I - K_k J_x^h)^T - v_k'^T] \right\}$$

$$= E[(I - K_k J_x^h) e_k^- e_k^{-T} (I - K_k J_x^h)^T - (I - K_k J_x^h) e_k^- v_k'^T - v_k' e_k^{-T} (I - K_k J_x^h)^T + v_k' v_k'^T]$$

$$= E[(I - K_k J_x^h) e_k^- e_k^{-T} (I - K_k J_x^h)^T] + E(v_k' v_k'^T)$$

$$= (I - K_k J_x^h) P_k^- (I - K_k J_x^h)^T + R'$$

回顾线性空间的 P_k 表达式

在线性空间中 $P_k = (I - K_k H) P_k^- (I - K_k H)^T + R$

发现 J_x^h 与线性空间的 H 作用类似

因此，不难得到 $K_k = \dfrac{P_k^- J_x^{hT}}{J_x^h P_k^- J_x^{hT} + R}$

同理易证 $P_k^- = J_x^f P_{k-1} J_x^{fT}$

习惯上，我们仍把 J_x^h 看作 h

把 J_x^f 看作 A，

K_k 仍为 $\dfrac{P_k^- H^T}{H P_k^- H^T + R}$ 和线性空间一致

这只是为了好看，实际上 J_x^h 和线性空间的 H 无关

总结 EKF 的步骤

① $\hat{x}_k^- = f(\hat{x}_{k-1}, u_{k-1}, 0)$

② $P_k^- = A P_{k-1} A^T + W Q W^T$

③ $K_k = \dfrac{P_k^- H^T}{H P_k^- H^T + V R V^T}$

④ $\hat{x}_k = \hat{x}_k^- + K_k (z_k - h(\hat{x}_k^-, 0))$

⑤ $P_k = (I - K_k H) P_k^-$

这里 A 为 $J^f_{x_{k-1}}$，H 为 $J^h_{x_k^-}$，与线性空间的 A、H 不同，只是写起来一样

提问：②③两步中的 WQW^T 和 VRV^T 是什么？

以 WQW^T 为例解释，VRV^T 与之同理

在 $x_k = f(\hat{x}_{k-1}, u_{k-1}, 0) + J^f_{x_{k-1}}(x_{k-1} - \hat{x}_{k-1})$ 中

我们说上式是错误的，因为没有误差项，所以我们在后面加了个 w_{k-1}，认为也是新误差，

实际上 $w_{k-1} = W \times w_{k-1}$

- w_{k-1} 为新误差
- w_{k-1} 是原本在方程中的过程误差
- W 是一个矩阵，$W = J^f_{w_{k-1}}$

为什么？我们上面做的是线性化，要求将所有非线性关系都变成线性（包括 w_{k-1}）

显然 w_{k-1} 与 x_k 是非线性的

将 w_{k-1} 线性化的方式就是左乘 $J^f_{w_{k-1}}$

为什么？假设 $w_{k-1} = \begin{bmatrix} w_1 \\ w_2 \\ w_3 \end{bmatrix}$ $J^f_{w_{k-1}} = \begin{bmatrix} \frac{dx_1}{dw_1} & \frac{dx_1}{dw_2} & \frac{dx_1}{dw_3} \\ \frac{dx_2}{dw_1} & \frac{dx_2}{dw_2} & \frac{dx_2}{dw_3} \\ \frac{dx_3}{dw_1} & \frac{dx_3}{dw_2} & \frac{dx_3}{dw_3} \end{bmatrix}$ $x_k = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}$

假设此时 w_{k-1} 的第一项发生变化

如 $w_{k-1} = \begin{bmatrix} w_1 + 1 \\ w_2 \\ w_3 \end{bmatrix}$ 即第一项变大 3

我们计算 $J^f_{w_{k-1}} w_{k-1} = \begin{bmatrix} \frac{dx_1}{dw_1} w_1 + \frac{dx_1}{dw_1} + \frac{dx_1}{dw_2} w_2 + \frac{dx_1}{dw_3} w_3 \\ \frac{dx_2}{dw_1} w_1 + \frac{dx_2}{dw_1} + \frac{dx_2}{dw_2} w_2 + \frac{dx_2}{dw_3} w_3 \end{bmatrix}$

$$\frac{\partial h_1}{\partial w_1} w_1 + \frac{\partial h_1}{\partial w_3} \quad + \frac{\partial h_3}{\partial w_2} w_2 + \frac{\partial h_3}{\partial w_3} w_3$$

这表明，由于 w_{k-1}，我们可以知道 w_{k-1} 变化时，对 X 的三个分量分别有什么变化，也就是线性化

因为 $W_{k-1}' = W \times W_{k-1}$　　$V_k' = V \times V_k$

协方差矩阵也发生变化 $Q' = WQW^T$　　$R' = VRV^T$