卡尔曼滤波

第一部分：引例

引例一： 汽车的行程 z

（可能不准）

$$\begin{cases} \text{估计：} z = 100\ km/h \times 1h = 100\ km \\ \text{导航：} z_2 = 110\ km \quad (\text{better}) \end{cases}$$

最理想的行程可能为 $z_{best} = 0.1 z_1 + 0.9 z_2 = 109\ km$

$$\begin{cases} \text{估计：} z_1 = 10\ km/h \times 5s = 13.89\ m \quad (\text{better}) \\ \text{导航：} z_2 = 5\ m \quad (\text{短距离导航不准}) \end{cases}$$

最理想的行程可能为 $z_{best} = 0.8 z_1 + 0.2 z_2 = 12.11\ m$

引例二： 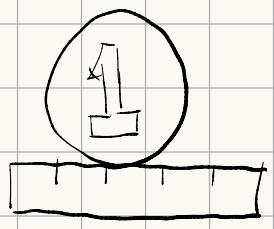 测量硬币的半径.

最优值显然为 $r_{best} = \hat{r}_n = \frac{1}{n}(r_1 + r_2 + \cdots + r_n)$ 取 n 个数据

变换 $\Rightarrow$ $= \frac{1}{n}(r_1 + r_2 + \cdots + r_{n-1}) + \frac{1}{n} r_n$

$= \frac{1}{n} \frac{n-1}{n-1}(r_1 + r_2 + \cdots + r_{n-1}) + \frac{1}{n} r_n$

$= \frac{n-1}{n} \hat{r}_{n-1} + \frac{1}{n} r_n$

$\Leftrightarrow \hat{r}_n = (1 - \frac{1}{n}) \hat{r}_{n-1} + \frac{1}{n} r_n$

$\Downarrow$ 更常用的形式

$\hat{r}_n = \hat{r}_{n-1} + \frac{1}{n}(r_n - \hat{r}_{n-1})$

不一定是前 $n-1$ 组的平均值与第 n 组数据融合，也可以是前 $n-m$ 组数据与后 m 组数据的融合

$\hat{r}_{n-1}$ 认为是一种估计方式

r_n 认为是另一种估计方式

$\hat{r}_n$ 认为是两种方式结果的融合

以上是从概率统计的角度对最优值的解释

思考：① 对于位置的状态量（如速度/距离/温度等）z，如果用两种方式估计得到 z_1, z_2

是否有 $\begin{cases} z_{best} = z_1 + k(z_2 - z_1) \\ \Updownarrow \end{cases}$ 其中 $k \in (0,1)$

$z_{best} = (1-k)z_1 + kz_2$

即 最优估计 = 估计值1 与 估计值2 的数据融合

② 在引例一中 估计值与导航值 相互独立.

在引例二中. 两个估计值 不相互独立.

对数据融合而言, 对两组数据 是否独立 无要求

但不相互独立的数据 融合 没有体现 数据融合的优势

相互独立的数据 融合才能发挥 数据融合的优势

在后续 均使用相互独立的数据

③ 如何寻找一个 k 使 z_{best} ($\hat{z}$) 最优?

第二部分. 数据融合

对于引例一 $\begin{cases} \text{估计} & z_1 = 100\,km \\ \text{导航} & z_2 = 110\,km \end{cases}$

$\hat{z} = z_1 + k(z_2 - z_1)$

如何找一个 k. 使 $\hat{z}$ 最优?

在概率统计中, 认为 z_1 与 z_2 是(可能)服从某种概率分布的统计量(如正态分布)

因此 $\hat{z}$ 也是一个统计变量 $\Rightarrow$ 有期望和方差

假设 $\sigma_1^2 = 8$

$\sigma_2^2 = 2$

找一个 k, 使 $\hat{z}$ 最优

找一个 k 使 $\hat{z}$ 方差最小 这是人为设定一个标准来标定 $\hat{z}$ 何时最优

$$\begin{aligned} Var(\hat{z}) &= Var[z_1 + k(z_2 - z_1)] \\ &= Var[(1-k)z_1] + Var(kz_2) \\ &= (1-k)^2\sigma_1^2 + k^2\sigma_2^2 \\ &= 8(1-k)^2 + 2k^2 \\ &= 10k^2 - 16k + 8 \end{aligned}$$

当 $k = 0.8$ 时 $Var(\hat{z})$ 取最小值.

此时 $\hat{z} = 108\,km$ $Var(\hat{z}) = 1.6$

这个方差小于 z_1 和 z_2 的

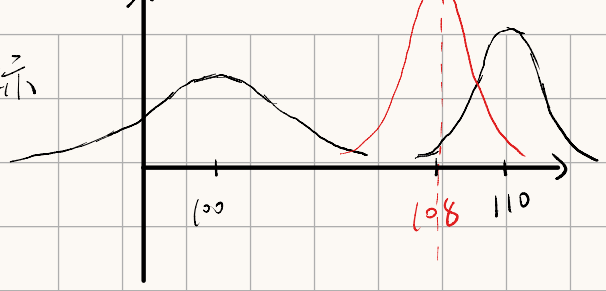

再图展示

为差，我们求的是最优

思考：回到这个式子 $\hat{z} = z_1 + K(z_2 - z_1)$

对于目标量 z，如果有 z_1 和 z_2 两种估计结果，我们就可以使用第二部分的思路求出 K，进一步求出最优 $\hat{z}$

那么对于任意状态量，我们怎么快速寻找两个相互独立的估计量？

第三部分：状态空间方程

$$\begin{cases} x_k = A x_{k-1} + B u_k + w_{k-1} \\ z_k = H x_k + v_k \end{cases}$$

x_k：当前状态；x_{k-1}：上一状态；u_k：外部输入；w_{k-1}：预测噪声 服从 $N(0, Q)$

A：某种变换；B：某种变换

z_k：观测值；H：某种变换；x_k：当前值；v_k：观测噪声 服从 $(0, R)$

以上是现代控制理论的状态空间方程，任意状态量的递推（线性）一方程

这两行公式的意义是：

从预测的角度：当前状态与三个因素有关，分别是上一状态、外部输入、预测噪声

从观测角度：当前状态与观测值和观测噪声有关

简单的例子，以引例一为例有：

$$\begin{cases} x_k = x_{k-1} + u\,\Delta t + w_{k-1} \\ z_k = x_k + v_{k-1} \end{cases}$$

x_k：当前路程；x_{k-1}：上一时刻路程；外部输入是时间 Δt

$A = 1$；$B = u$

$H = 1$

z_k：测量值：导航数据

其中 A B H 可以是矩阵形式，但例子不太好举

噪声是不可预测的，我们使用上面式做估计

$$\begin{cases} \hat{x}_k^- = A\hat{x}_{k-1} + Bu_k \\ z_k = H\hat{x}_{k\,mea} \end{cases} \Leftrightarrow \hat{x}_{k\,mea} = H^- z_k$$

得到两个估计值 $\hat{x}_k^-$ 与 $\hat{x}_{k\,mea}$.

利用 $\hat{z} = z_1 + K(z_k - z_1)$ 公式估计

$$\hat{x} = \hat{x}_k^- + K(\hat{x}_{k\,mea} - \hat{x}_k^-)$$

$$= \hat{x}_k^- + K(H^- z_k - \hat{x}_k^-)$$

可得上式 $K = K_k H$

$$\hat{x}_k = \hat{x}_k^- + K_k(z_k - H\hat{x}_k^-)$$

第四部分，正式进入卡尔曼滤波推导

$$\hat{x}_k = \hat{x}_k^- + \underset{n\times m}{K_k}\left(\underset{m\times 1}{z_k} - \underset{m\times n}{H}\underset{n\times 1}{\hat{x}_k^-}\right)$$

寻找 K_k 使 $\hat{x}_k$ 最优 这里最优的标准不是 x_k 的方差最小，因为无法计算，也无法得到普遍规律

采用新的评判 $\hat{x}_k$ 最优的方法

令 $e_k = x_k - \hat{x}_k$ 注意 x_k 是真实值

求 e_k 方差最小的情况 (在数学上定义为协方差矩阵的迹的大小)

求 e_k 的协方差矩阵 P (之前也提到了两个协方差矩阵，分别是预测噪声 w_{k-1} 的协方差 Q，观测噪声的协方差矩阵 R.)

引入数学公式

$$Cov(X) = E\left[(X-u)(X-u)^T\right]$$

μ为均值，如果$\mu=0$，则 $Cov(x)=E(xx^T)$

e_k为真实值与最优估计的差，最优估计中包含过程噪声与测量噪声的加权融合，因此总体误差e_k保留了w_{k-1}和v_k的特征，服从均值为0的正态分布（w_{k-1}和v_k相互独立）

定量运算证明 $E(e_k)=0$ 有点困难

$$
\begin{aligned}
e_k &= x_k - \hat{x}_k \\
&= x_k - (\hat{x}_k^- + K_k(z_k - H\hat{x}_k^-)) \\
&= x_k - \hat{x}_k^- - K_k z_k + K_k H \hat{x}_k^- \\
&= x_k - \hat{x}_k^- - K_k H x_k - K_k v_k + K_k H \hat{x}_k^- \\
&= (I - K_k H)(x_k - \hat{x}_k^-) - K_k v_k \\
&= (I - K_k H)\, e_k^- - K_k v_k
\end{aligned}
$$

$$
\begin{aligned}
P &= E(e_k e_k^T) \\
&= E\{[(I-K_kH)e_k^- - K_k v_k][(I-K_kH)e_k^- - K_k v_k]^T\} \\
&\qquad \Downarrow \\
&\qquad [e_k^{-T}(I-K_kH)^T - v_k^T K_k^T] \\
&= E[(I-K_kH)e_k^- e_k^{-T}(I-K_kH)^T] - E[(I-K_kH)e_k^- v_k^T K_k^T] \\
&\quad - E(K_k v_k e_k^{-T}(I-K_kH)^T) + E(K_k v_k v_k^T K_k^T) \\
&\qquad \text{常量} \quad E(v_k)=0 \quad \text{常量} \\
&= E[(I-K_kH)e_k^- e_k^{-T}(I-K_kH)^T] - 0 - 0 + E(K_k v_k v_k^T K_k^T) \\
&= (I-K_kH)\,E(e_k^- e_k^{-T})\,(I-K_kH)^T + K_k E(v_k v_k^T) K_k^T \\
&\qquad \text{常量} \quad \text{令其为 } P_k^- \quad \text{常量} \qquad v_k \text{ 服从正态分布，均值为0，并协方差矩阵 } R = E(v_k v_k^T) \\
&= (I-K_kH)\,P_k^-\,(I-K_kH)^T + K_k R K_k^T \\
&\qquad (I - H^T K_k^T)
\end{aligned}
$$

$$P_k = P_k^- - P_k^- H^T K_k^T - K_k H P_k^- + K_k H P_k^- H^T K_k^T + K_k R K_k^T$$

目标：求当 K_k 为何值时，协方差矩阵的迹最小

先求迹 $tr(P_k)$ → 对 K_k 求导 → 令导数 $\frac{d\,tr(P_k)}{dK_k} = 0$

$$tr(P_k) = tr(P_k^-) - tr(P_k^- H^T K_k^T) - tr(K_k H P_k^-) + tr(K_k H P_k^- H^T K_k^T) + tr(K_k R K_k^T)$$

引入数学定理 $\frac{d\,tr(AB)}{dA} = B^T$

设 AB 为 $n \times n$ 矩阵，则 $AB_{ij} = \sum_{k=1}^{n} A_{ik} B_{kj}$

$$tr(AB) = \sum_{i=1}^{n} \sum_{j=1}^{n} A_{ij} B_{ji}$$，求 $\frac{d\,tr(AB)}{dA} = D$

$$D_{xy} = \frac{\partial\, tr(AB)}{\partial A_{xy}} = B_{yx}$$

$\therefore D = B^T$ 即 $\frac{d\,tr(AB)}{dA} = B^T$

$$tr(ABA^T) = \sum_{i=1}^{n} \sum_{j=1}^{n} \sum_{k=1}^{n} A_{ij} B_{jk} A^T_{ki}$$

$A^T_{ki} = A_{ik}$

求 $\frac{d\,tr(ABA^T)}{dA}$ ⇒

$$D_{xy} = \frac{\partial\, tr(ABA^T)}{\partial A_{xy}} = \sum_{k=1}^{n} B_{yk} A^T_{kx} + \sum_{j=1}^{n} A_{xj} B_{jy}$$

$$= (BA^T)_{yx} + (AB)_{xy}$$

$$= (AB^T)_{xy} + (AB)_{xy}$$

$\therefore D = AB^T + AB$

如果 B 是对称阵 $\frac{d\,tr(ABA^T)}{dA} = 2AB$

$tr(AB) = tr(BA)$

$$tr(P_k) = tr(P_k^-) - tr(P_k^- H^T K_k^T) - tr(K_k H P_k^-) + tr(K_k H P_k^- H^T K_k^T) + tr(K_k R K_k^T)$$

这两个式子相同

$$\frac{d\,tr(P_k)}{d\,K_k} = 0 - 2\frac{d\,tr(K_k H P_k^-)}{d\,K_k} + 2K_k H P_k^- H^T + 2K_k R$$

$$\frac{d\,tr(K_k H P_k^-)}{d\,K_k} = (H P_k^-)^T$$

令 $\frac{d\,tr(P_k)}{d\,K_k} = 0$ 求极小值

得 $P_k^- H^T = K_k (H P_k^- H^T + R)$

Kalman Gain 卡尔曼增益

$$K_k = \frac{P_k^- H^T}{H P_k^- H^T + R}$$ → 观测噪声的协方差矩阵

反应的是过程噪声的影响程度

当观测噪声的影响更大，$K_k \to 0$，更相信预测值

当过程噪声的影响更大，$K_k \to H^-$，更相信观测值

如何求 P_k^- 那如何求 $\hat{e}_k^-$ 的协方差矩阵

$$\hat{e}_k^- = x_k - \hat{x}_k^-$$

$$x_k = A x_{k-1} + B u_k + w_{k-1}$$

$$\hat{x}_k^- = A \hat{x}_{k-1} + B u_k$$

$$x_k - \hat{x}_k^- = A(x_{k-1} - \hat{x}_{k-1}) + w_{k-1}$$

$$= A e_{k-1} + w_{k-1}$$

$$\hat{e}_k^- = A(x_{k-1} - \hat{x}_{k-1}) + w_{k-1}$$

$$P_k^- = E(\hat{e}_k^- \hat{e}_k^{-T})$$

$$= E[(A e_{k-1} + w_{k-1})(A e_{k-1} + w_{k-1})^T]$$

$$= E[(A e_{k-1} + w_{k-1})(e_{k-1}^T A^T + w_{k-1}^T)]$$

$$= E(A e_{k-1} e_{k-1}^T A^T + A e_{k-1} w_{k-1}^T + w_{k-1} e_{k-1}^T A^T + w_{k-1} w_{k-1}^T)$$

易证这两项的期望为0

$$= E(A e_{k-1} e_{k-1}^T A^T) + E(w_{k-1} w_{k-1}^T)$$

$$= E(Ae_{k-1}e_{k-1}^T A^T) + E(w_{k-1}w_{k-1}^T)$$

$$= A\,E(e_{k-1}e_{k-1}^T)A^T + E(w_{k-1}w_{k-1}^T)$$

$P_k^- = A P_{k-1} A^T + Q$ → Q是过程噪声w的协方差矩阵

这里说明 P_k^- 是能反映过程噪声大小的

求 P_k^- 需要用到 P_{k-1} 是否应该求 P_k 为 P_{k+1} 的计算做准备？

$P_k = P_k^- - P_k^- H^T K_k^T - K_k H P_k^- + K_k H P_k^- H^T K_k^T + K_k R K_k^T$ （之前已经推了）

$= P_k^- - P_k^- H^T K_k^T - K_k H P_k^- + K_k (H P_k^- H^T + R) K_k^T$

↓代入

$= P_k^- - P_k^- H^T K_k^T - K_k H P_k^- + \frac{P_k^- H^T}{H P_k^- H^T + R} (H P_k^- H^T + R) K_k^T$

$= P_k^- - P_k^- H^T K_k^T - K_k H P_k^- + P_k^- H^T K_k^T$

$= P_k^- - K_k H P_k^-$

$= (I - K_k H) P_k^-$

卡尔曼滤波步骤

① $\hat{X}_k^- = A\hat{X}_{k-1} + Bu_k$

② $P_k^- = A P_{k-1} A^T + Q$

③ $K_k = \frac{P_k^- H^T}{H P_k^- H^T + R}$

④ $\hat{X}_k = \hat{X}_k^- + K_k (Z_k - H\hat{X}_k^-)$

⑤ $P_k = (I - K_k H) P_k^-$

数据融合 → 怎样求合适的 K？→ 方差最小

怎样获得任意变量的两个相互独立的估计值 → 状态空间方程

寻找 Kalman Gain? → $e_k = x_k - \hat{x}_k$ 求 e_k 的方差最小时 K_k 的值

→ 即求 e_k 的协方差矩阵 P 的迹 $tr(P)$ 最小时 K_k 的值

→ 求 $tr(P)$，求导，令导数等于 0 得到 Kalman Gain

扩展卡尔曼滤波

非线性系统 $x_k = f(x_{k-1}, u_{k-1}, w_{k-1})$ $w \sim N(0, Q)$

$z_k = h(x_k, v_k)$ $v \sim N(0, R)$

正态分布经过非线性映射就不再正态

非线性系统线性化

泰勒展开 $f(x) = f(x_0) + \frac{df}{dx}(x - x_0)$ 对于多元函数，如 $X = \begin{bmatrix} x_0 \\ x_1 \\ x_2 \end{bmatrix}$ 需要求雅可比矩阵

多元泰勒展开 $f(x) = f(x_0) + A(x - x_0)$ 其中 $A = \begin{pmatrix} \frac{df_1}{dx_1} & \frac{df_1}{dx_2} & \frac{df_1}{dx_3} \\ \frac{df_2}{dx_1} & \frac{df_2}{dx_2} & \frac{df_2}{dx_3} \\ \frac{df_3}{dx_1} & \frac{df_3}{dx_2} & \frac{df_3}{dx_3} \end{pmatrix}$

↓ 在定点的线性化不准确

对 $x_k = f(x_{k-1}, u_{k-1}, w_{k-1})$ 的多元泰勒展开在 $\hat{x}_{k-1}$ 处 ($k-1$ 时刻的最优估计)

为了便于估计，假设误差为 0

$x_k = f(\hat{x}_{k-1}, u_{k-1}, w_{k-1}) + A(x_k - \hat{x}_{k-1}) + w * w_{k-1}$ 其中 $A = \frac{df}{dx}\Big|_{\hat{x}_{k-1}, u_{k-1}}$

$$\begin{pmatrix} \frac{df_1}{dx_1} & \frac{df_1}{dx_2} & \cdots & \frac{df_1}{dx_n} \\ \frac{df_2}{dx_1} & \frac{df_2}{dx_2} & \cdots & \frac{df_2}{dx_n} \\ \vdots & \vdots & & \vdots \\ \frac{df_n}{dx_1} & \frac{df_n}{dx_2} & \cdots & \frac{df_n}{dx_n} \end{pmatrix}$$

$W = \frac{df}{dw}\Big|_{\hat{x}_{k-1}, u_{k-1}}$

令 $\tilde{x}_k = f(\hat{x}_{k-1}, u_{k-1}, 0)$

z_k 在 $\tilde{x}_k$ 处展开

$z_k = h(\tilde{x}_k, v_k) + H(x_k - \tilde{x}_k) + V * v_k$

$H = \frac{dh}{dx}\Big|_{\tilde{x}_k}$ $V = \frac{dh}{dv}\Big|_{\tilde{x}_k}$

$z_k = \tilde{z}_k + H(x_k - \tilde{x}_k) + V * v_k$

总结 $\begin{cases} x_k = \tilde{x}_k + A(x_{k-1} - \hat{x}_{k-1}) + W * w_{k-1} \\ z_k = \tilde{z}_k + H(x_k - \tilde{x}_k) + V * v_k \end{cases}$ （W矩阵）

$W * w_{k-1} \sim N(0, WQW^T)$

$V * v_k \sim N(0, VRV^T)$

EKF 的流程

$\tilde{x}_k = f(\hat{x}_{k-1}, w_{k-1}, 0)$

$\tilde{P}_k = AP_{k-1}A^T + WQW^T$

$K_k = \frac{\tilde{P}_k H^T}{H\tilde{P}_k H^T + VRV^T}$

$\hat{x}_k = \tilde{x}_k + K_k(z_k - h(\tilde{x}_k, 0))$

$P_k = (I - K_k H)\tilde{P}_k$

补充

状态空间的表达：弹簧振动阻尼系统

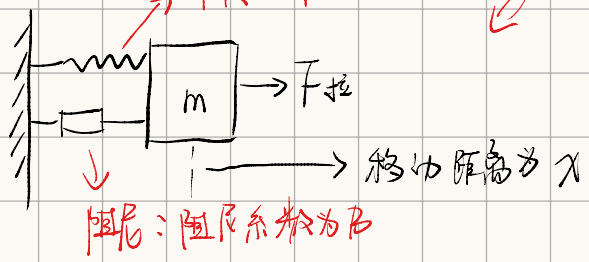

（另外，物体有在对 距离和速度 的影响）

$F_合 = ma$

$F_{拉} - Kx - Bv = ma$

$F_{拉} = kx + Bv + ma$ 可移上写成 $F = kx + B\dot{x} + m\ddot{x}$（分别是1阶2阶导）

可移上令 $F = u$，即外部输入

$F = kx + B\dot{x} + m\ddot{x}$

令 $x_1 = x$ 距离

$x_2 = \dot{x}$ 速度

求 $\dot{x}_1$ 和 $\dot{x}_2$

$$\begin{cases} \dot{x}_1 = x_2 \\ \dot{x}_2 = \ddot{x} = \frac{1}{m}u - \frac{1}{m}Kx - \frac{1}{m}B\dot{x} \end{cases}$$

(x_1, x_2)

$$\begin{cases} \dot{x}_1 = x_1 \\ \dot{x}_2 = \frac{1}{m}u - \frac{1}{m}Kx_1 - \frac{1}{m}Bx_2 \end{cases} \Rightarrow \begin{bmatrix} \dot{x}_1 \\ \dot{x}_2 \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ -\frac{K}{m} & -\frac{B}{m} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + \begin{bmatrix} 0 \\ \frac{1}{m} \end{bmatrix} u$$

$$\dot{X}(t) = A \quad X(t) + B \quad ut$$

对上式做离散化处理

$$X(t) = X(t-1) + \dot{X}(t-1)\,dt$$

$$\downarrow$$

$$(A\,X(t-1) + B\,ut-1)\,dt$$

$$= (I + A\,dt)\,X(t-1) + B\,dt\;ut-1$$

令 $A = I + A\,dt$

$B = B\,dt$

$$X(t) = A\,X(t-1) + B\,ut-1$$

新的A　　新的B

即 $X_k = A\,X_{k-1} + B\,u_{k-1} + W_{k-1}$　　式①

另外，还存在观测量 $\begin{cases} z_1 = x_1 \\ z_2 = x_2 \end{cases}$

$$\begin{bmatrix} z_1 \\ z_2 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + V_k$$

$$\downarrow$$

$$z_k = H\,x_k + V_k$$

式②

联结式①式②，得到方程

$$\begin{cases} X_k = A\,X_{k-1} + B\,u_{k-1} + W_{k-1} \\ z_k = H\,x_k + V_k \end{cases}$$

发现其后线性状态量也服从这个式子，得其总结为状态空间方程

为什么不以 x_k 误差最小为标准，而是以 $e = x_k - \hat{x}_k$ 误差最小

补充：

$$\hat{x}_k = \hat{x}_k^- + K_k(z_k - H\hat{x}_k^-)$$

求 $\mathrm{var}(\hat{x}_{k|k}) = P = E[(\hat{x}_{k|k}-u)(\hat{x}_{k|k}-u)^T]$

↳ u 未知，应先求 $u = E(\hat{x}_{k|k})$

$E(\hat{x}_{k|k}) = E[(I-K_kH)\hat{x}_{k|k} + K_k z_k]$

$= (I-K_kH)\,E(\hat{x}_{k|k}) + K_k\,E(z_k)$

$K_kH\,E(x_{k|k})$

$$\begin{cases} \hat{x}_{k|k} = A\hat{x}_{k-1} + Bu_{k-1} \\ z_k = H x_{k\,mea} \end{cases}$$

$E(A\hat{x}_{k-1} + Bu_{k-1})$

$= A\,E(\hat{x}_{k-1}) + B u_{k-1}$

↳ 可以迭代

↳ 外部输入是来知的，不可预测的。如弹簧振动回复系统中的 F 不是一个随机变量，无均值

$= (I-K_kH)[A\,E(\hat{x}_{k-1}) + Bu_{k-1}] + K_kH\,E(x_{k|k})$

$= (I-K_kH)A\,E(\hat{x}_{k-1}) + (I-K_kH)B u_{k-1} + K_kH\,E(x_k)$

x_k 是 $n\times1$ 向量　z_k 是 $m\times1$　H 是 $m\times n$　K_k 是 $n\times m$　Bu_k 是 $n\times1$

$$\mathrm{Var}(\hat{x}_{k|k}) = P = E\Big\{[\hat{x}_{k|k} - (I-K_kH)AE(\hat{x}_{k-1}) - (I-K_kH)Bu_{k-1} - K_kHE(x_{k|k})]$$

$$[\hat{x}_{k|k}^T - E^T(\hat{x}_{k-1})A^T(I-K_kH)^T - u_{k-1}^T B^T (I-K_kH)^T - E^T(x_{k|k})H^T K_k^T]\Big\}$$

展开后为比项和的期望

$$P = E\Big[\underset{n\times1\ 1\times n}{\hat{x}_k\hat{x}_{k|k}^T} - \underset{n\times1\ 1\times n}{\hat{x}_{k|k}E^T(\hat{x}_{k-1})}\underset{n\times n}{A^T}\underset{n\times n}{(I-K_kH)^T} - \underset{n\times1\ 1\times n}{\hat{x}_{k|k}u_{k-1}^T}\underset{n\times n}{B^T}\underset{n\times n}{(I-K_kH)^T} - \underset{n\times1\ 1\times n}{\hat{x}_{k|k}E^T(x_{k|k})}\underset{n\times m\ m\times n}{H^T K_k^T}$$

$$-(I-K_kH)AE(\hat{x}_{k-1})\hat{x}_{k|k}^T + (I-K_kH)AE(\hat{x}_{k-1})E^T(\hat{x}_{k-1})A^T(I-K_kH)^T + (I-K_kH)AE(\hat{x}_{k-1})u_{k-1}^T B^T(I-K_kH)^T$$

$$+(I-K_kH)AE(\hat{x}_{k-1})E^T(x_{k|k})H^T K_k^T - (I-K_kH)Bu_{k-1}\hat{x}_{k|k}^T + (I-K_kH)Bu_{k-1}E^T(\hat{x}_{k-1})A^T(I-K_kH)^T$$

$$+(I-K_kH)Bu_{k-1}u_{k-1}^T B^T(I-K_kH) + (I-K_kH)Bu_{k-1}E^T(x_{k|k})H^T K_k^T - K_kHE(x_{k|k})\hat{x}_{k|k}^T$$

$$+K_kHE(x_{k|k})E^T(\hat{x}_{k-1})A^T(I-K_kH)^T + K_kHE(x_{k|k})u_{k-1}^T B^T(I-K_kH)^T + K_kHE(x_{k|k})E^T(x_{k|k})H^T K_k^T\Big]$$

转化为比项期望的和

$P = E[\hat{x}_k \hat{x}_k^T] + E[\dots] + \dots + E[\dots] + E[K_k H E[x_k] E^T[x_k] H^T K_k^T]$

接下来 求 $tr(P) \rightarrow$ 求 $\frac{d\,tr(P)}{dK_k} \rightarrow$ 令 $\frac{d\,tr(P)}{dK_k} = 0$ 得 K_k

$tr(P) = tr[E(\hat{x}_k \hat{x}_k^T)] + tr[E(\dots)] + \dots + tr[E(\dots)] + tr[E(K_k H E[x_k] E^T[x_k] H^T K_k^T)]$

$\frac{d\,tr(P)}{dK_k} = \dots$ 尝试求第1项对 K_k 的导数

$\frac{d\,tr[E(\hat{x}_k \hat{x}_k^T)]}{dK_k} = \frac{d\,tr\{E[(\hat{x}_k^- + K_k z_k - K_k H \hat{x}_k^-)][(\hat{x}_k^{-T} + z_k^T K_k^T - \hat{x}_k^{-T} H^T K_k^T]\}}{dK_k}$

$E(\hat{x}_k \hat{x}_k^T) = E(\hat{x}_k \hat{x}_k^{-T} + \hat{x}_k^- z_k^T K_k^T + \hat{x}_k^- \hat{x}_k^{-T} H^T K_k^T$

太复杂了，不算了

跟据上面的式子来必能算出 K_k，从 K_k 的本质说起

本质上 $K = \frac{e_{est}}{e_{est} + e_{mea}}$

e_{est}：过程误差　e_{mea}：观测误差

$\hat{x} = (1-K)x_1 + Kx_2 = x_1 + K(x_2 - x_1)$

当 e_{est} 大于 e_{mea}，即过程误差大，观测误差小：$K \rightarrow 1$　$\hat{x} \rightarrow x_2$ 更相信观测值

当 e_{est} 小于 e_{mea} 即过程误差小，观测误差大　$K \rightarrow 0$　$\hat{x} \rightarrow x_1$ 更相信预测值

因此，只有引入误差 e，才可能算出 K_k

$P = var(\hat{x}_k)$ 中没有误差，没有 w_{k-1} 和 v_k 怎么能算出正确的 K_k 呢？

或者含有误差的项占比很小

因此引入 $e_k = x_k - \hat{x}_k$

为什么在第二部分的例子中 可以直接用 $var(\hat{x}_k)$ 因为两个估计变量 x_1 x_2 的方差是已知的，可以直接计算结果