挑战点四

加速度计与牛顿高斯迭代

1.加速度计

核心原理：牛顿第二定律，F=ma;

对于一个已知质量（m）的物体，如果测得了它所受的力（F），就能计算出它的加速度（a）。

在加速度计内部，这个“已知质量的物体”是一个微小的、可移动的结构，通常被称为**质量块**或**检测质量**。

核心技术：MEMS（微机电系统）

不多加赘述，其核心结构可以想象成一个**微型的“弹簧-质量块”系统**。在质量块的前、后、上、下、左、右等位置有固定的电容极板。质量块本身也作为一个可动的电容极板。加速度的变化会导致质量块与固定极板之间的距离的改变，从而改变电容值（C = ε * A / d），通过测量电容差，可以计算出质量块的位移量，再根据胡克定律（F = k × x，弹簧力 = 弹性系数 × 位移量）和牛顿第二定律，最终换算出施加在该轴上的加速度值（a = F / m）。

2.误差

分为系统性误差与随机性误差两类。因为仅系统性误差可以通过校准来消除或大幅减小，仅讨论系统性误差

1. **零偏误差**

- **描述**：当输入加速度为零（或已知，如静止时的重力）时，加速度计的输出值与真实值之间的固定偏差。
- **示例**：飞控水平静止时，X轴理论输出应为0g，但实际输出为0.05g。这0.05g就是X轴的零偏。
- **影响**：导致姿态角（俯仰、横滚）测量出现固定偏差。

2. **刻度因数误差**

- **描述**：加速度计输出值与真实输入值之间的比例关系不准确。理想斜率是1，但实际可能存在偏差。
- **示例**：承受2.10g的加速度时，传感器输出2.00g。其刻度误差为2.1/2.0=1.05。
- **影响**：导致所有量程上的加速度和角度测量值按比例失真。

设三轴加速度计的零偏误差与刻度误差分别为： ox,oy,oz;sx,sy,sz

某一时刻该三轴加速度计的测量值分别为： x,y,z

设当前时刻真实加速度向量为 :a=(ax,ay,az)

可得以下关系：

$$\begin{cases} a_x = (x - o_x)s_x \\ a_y = (y - o_y)s_y \\ a_z = (z - o_z)s_z \end{cases}$$

同时在静止状态下，校正后的加速度矢量模长应等于1g，故而：
ax^2+ay^2+az^2=1;
我们的任务就是利用多组 `(x, y, z)` 数据，求解出最优的 `[ox,oy,oz;sx,sy,sz]` 这6个参数。

那么，为什么我们不直接找到6个（x,y,z）的值来进行计算呢?

问题就在于，我们生活的世界是**不完美**的。我们获得的每一个 `(x, y, z)` 数据都包含两种主要的“污染”：

a) 随机噪声

这是最致命的原因。加速度计的读数从来都不是一个干净的值。它时刻被随机白噪声所污染。假设我们将飞控静止放在桌面上，读数不会是稳定的 `(0.01, 0.02, 1.00)`，而可能是：

- 时刻1: `(0.012, 0.019, 1.003)`
- 时刻2: `(0.009, 0.022, 0.998)`
- 时刻3: `(0.011, 0.018, 1.001)`

如果只取**一个瞬间**的读数作为那个姿态的代表，那么这个读数本身就包含了随机误差。如果用6个这样的“脏”数据点去求解方程组，**解会变得极不稳定**：方程组会试图**精确地拟合这6个包含噪声的数据点**。结果就是，求出的 `ox, Sx` 等参数也会包含巨大的随机误差，甚至可能得到完全离谱的解。这个解对于本次用的这6个特定点来说是“完美”的，但对于其他任何点都是错误的。这被称为**过拟合**。

b) 模型不完善

我们的线性模型 `校准值 = 刻度误差 * (原始值 - 零偏)` 本身就是一个**简化模型**。它没有考虑：

- **非正交误差**：三个轴可能不是完全90度垂直。
- **非线性**：刻度因数本身可能随加速度大小轻微变化。
- **温漂**：校准过程中温度可能已经发生了变化。

故而，我们需要通过数学手段得到我们理想的六个参数。

3.数据拟合

最小二乘法

最小二乘法的核心思想是：寻找一组模型参数，使得模型的预测值与实际观测值之间的误差平方和达到最小。

通过最小二乘法，我们将求六个未知数的问题转化为了求极值。

致命问题：1.无法迭代，而且偏差较大。2.分别计算

牛顿法

牛顿法的核心思想可以用一个简单的比喻来理解：

你站在一片起伏的山坡上，蒙着眼睛，想要找到山谷的最低点（最优化问题）。你如何做？

1. 你用脚探测当前位置的坡度（一阶导数）和地面的弯曲程度（二阶导数）。
2. 你假设你脚下的这一小片地方是一个抛物线形状。
3. 你计算出这个抛物线的最低点（或零点）在哪里，然后一步走到那个点。
4. 在新位置上，重复这个过程，直到你认为已经足够接近目标。

牛顿法做的就是这件事：在每一步迭代中，它都用一个二次函数来局部近似目标函数，然后直接跳到这个二次模型的最优解点。

在用数学方式讲解牛顿法时，我们需要先回忆一下泰勒公式。

一元函数fx在xk处的泰勒展开：

$$f(x)=f(x_k)+(x-x_k)f'(x_k)+\frac{1}{2!}(x-x_k)^2f''(x_k)+o^n$$

如何用牛顿法求根？

牛顿求根法的目标很简单：找到一个数 x*，使得函数 f(x*)=0。

它的几何直觉非常清晰：

1. 首先猜一个根的位置 x0（要较为接近）。
2. 在点 (x0,f(x0))处作函数 f(x)的切线。
3. 这条切线是一条直线，我们可以轻松地找到它与 x 轴的交点 x1。
4. 由于切线是函数在 x0附近的线性近似，我们认为交点 x1比最初的猜测 x0更接近函数真正的根。
5. 将 x1作为新的起点，重复这个过程。

$$x_{n+1}=x_n-\frac{f(x_n)}{f'_{(x_n)}}$$

根据上面的流程，可以逐步求得f(x)=0 的根。

如何用牛顿法求函数极值?

我们在前面知道了求解函数的根的方法，那么和函数的极值有什么关系呢？我们知道函数的极值的必要条件是其一阶微分等于0。那么求解微分方程为0时候的值，从而得到函数的极值了。

为了能够方便理解整个流程，我们还是拿一元函数f(x)来举例。

我们首先对其在 $x = x_0$ 处进行二阶泰勒展开：

$$f(x) = f(x_0) + f^{'}(x_0)(x - x_0) + \frac{f^{''}(x_0)}{2}(x - x_0)^2 + o(x - x_0)^2$$

其中，由于泰勒展开的特性，后面 $o(x - x_0)$ 部分不予考虑，我们只考虑前面展开部分的极值问题：

$$g(x) = f(x_0) + f^{'}(x_0)(x - x_0) + \frac{f^{''}(x_0)}{2}(x - x_0)^2$$

上面的式子是一个一元二次函数，那么其极值就是一阶导数为0的时候，我们可以先微分：

$$g^{'}(x) = f^{'}(x_0) + f^{''}(x_0)(x - x_0)$$

令 $g^{'}(x_1) = 0$ ，则此时的 x_1 就是极值（为了方便说明，暂不考虑鞍点的情况）。

故 $f^{'}(x_0) + f^{''}(x_0)(x_1 - x_0) = 0$

$$x_1 = x_0 - \frac{f^{'}(x_0)}{f^{''}(x_0)}$$

以此类推，可以得到迭代公式：

$$x_{n+1} = x_n - \frac{f^{'}(x_n)}{f^{''}(x_n)}$$

根据这个方法就可以不断的迭代下去直到收敛，最终找到极值了。

为什么可以忽略高阶项?

- 即使由于忽略了高阶项，这个谷底不是真实函数*F*(*x*) 的精确谷底，但只要这个方向是下降方向（即能使得*F*(*x*) 减小），那么这次迭代就是成功的。

- 我们并不指望一步就跳转到精确解。我们只是希望每一步都能显著降低函数值。一旦我们移动到了新点 xk+1，我们会重新进行泰勒展开，构建一个新的、更准确的局部二次模型。在这个过程中，之前被忽略的高阶项的影响会被逐步修正。

为什么没有三阶导的保留?

原因如下：

可行性：二次模型是可解析求解的最复杂模型

- 一次模型（线性）：太简单。它的导数是常数，没有极值点（除非是水平线），无法用于寻找极小值。
- 二次模型：是第一个拥有抛物线形状并能给出一个明确极值点的简单模型。这个极值点可以通过解一个简单的线性方程 g′(x)=0$g'(x)=0$ 直接求出。
- 三次及更高阶模型：一旦引入三阶导数，模型 g(x)就变成了一个三次函数。三次函数的导数是一个二次函数，令其为零（即 g′(x)=0）可能会得到两个临界点（一个极大值、一个极小值），甚至可能没有实数解。判断哪个是需要的极小值点本身又成为一个需要解决的优化子问题，这使得计算变得复杂，失去了简化模型的意义。

一句话总结：二次模型是“性价比”最高的模型——它既包含了曲率信息，其极值点又容易计算。

多元函数牛顿法（介绍一下多元函数泰勒展开）

已知：多元函数的二阶泰勒展式：

$f(X)$ 在点 $X_0(x_1^{(0)}, x_2^{(0)}, \cdots, x_n^{(0)})$ 处：

$$f(X) = f(X_0) + \sum_{i=1}^{n}(x_i - x_i^{(0)}) f'_{x_i}(x_1^{(0)}, x_2^{(0)}, \cdots, x_n^{(0)}) + \frac{1}{2!}\sum_{i=1}^{n}\sum_{j=1}^{n}(x_i - x_i^{(0)})(x_j - x_j^{(0)}) f''_{ij}(x_1^{(0)}, x_2^{(0)}, \cdots, x_n^{(0)}) + o[(X-X_0)^2]$$

$$= f(X_0) + \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \cdots, \frac{\partial f}{\partial x_n}\right)_{X_0}(X - X_0) + \frac{1}{2}(X-X_0)^T \begin{bmatrix} f_{x_1x_1} & f_{x_1x_2} & f_{x_1x_3} & \cdots & f_{x_1x_n} \\ f_{x_2x_1} & f_{x_2x_2} & \cdots & \cdots & f_{x_2x_n} \\ \vdots & \vdots & & & \vdots \\ f_{x_nx_1} & f_{x_nx_2} & \cdots & \cdots & f_{x_nx_n} \end{bmatrix}(X - X_0)$$

$$= f(X_0) + [\nabla f(X_0)]^T (X - X_0) + \frac{1}{2}(X-X_0)^T H(X_0)(X-X_0)$$

其中 $\nabla f(X_0)$ 称为梯度，也可用 J，g 代替，又称雅各比矩阵，

$H(X_0)$ 称为黑塞矩阵（海瑟 hessian）

多元函数的牛顿法：

已知一元：$x = x_0 - \frac{f'(x_0)}{f''(x_0)}$ 是对二阶泰勒两边求导 $f'(x) = f'(x_0) + f''(x_0)(x - x_0)$

则对于多元函数：$f(X) \approx f(X_0) + [\nabla f(X_0)]^T (X - X_0) + \frac{1}{2}(X-X_0)^T H(X_0)(X-X_0)$

两边同时取梯度：$\nabla f(X) \approx \nabla f(X_0) + H(X_0)(X - X_0)$

这里转置　　先假设是这样，由一元类比得来

证明：$\nabla(X^T H X) = 2HX$

已知：H 为对称矩阵，$H = H^T$.

则：$X^T H X = \sum_{i=1}^{n}\sum_{j=1}^{n} a_{ij} x_i x_j$

$$\nabla(X^T H X) = \nabla\left[\sum_{i=1}^{n}\sum_{j=1}^{n} a_{ij} x_i x_j\right]$$

对 x_k 求偏导可得：

$$\frac{\partial(X^T H X)}{\partial x_k} = \frac{\partial}{\partial x_k}\left[\sum_{i=1}^{n}\sum_{j=1}^{n} a_{ij} x_i x_j\right]$$

$$= 2a_{kk}x_k + \sum_{i=1(i\neq k)}^{n} a_{ik} x_j + \sum_{j=1(j\neq k)}^{n} a_{kj} x_j$$

$$= 2a_{kk}x_k + \sum_{i=1(i\neq k)}^{n} a_{ik} x_i + \sum_{j=1(j\neq k)}^{n} a_{jk} x_j$$

$$= 2\sum_{i=1}^{n} a_{ik} x_i$$

~~$\nabla(X^T H X) = \sum_{i=1}^{n}\sum_{j=1}^{n} a_{ik} x_i$~~

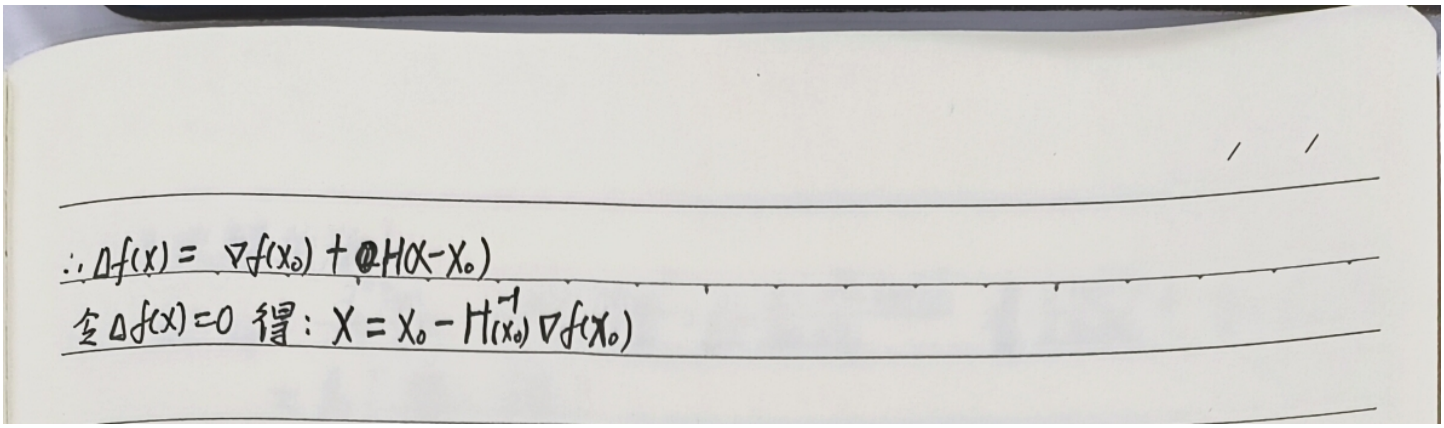
~~$= 2\sum_{i=1}^{n}\sum_{j=1}^{n} a_{ij} x_i$~~

~~$= 2HX$~~

$$\therefore \nabla(X^T H X) = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{pmatrix}(X^T H X)$$

$$= 2\begin{pmatrix} \sum_{i=1}^{n} a_{ik} x_i \\ \vdots \\ \sum_{i=1}^{n} a_{nk} x_n \end{pmatrix}$$

$$= 2HX$$



高斯牛顿迭代

由 $\nabla(X^THX) = 2HX$ 得:

$\nabla f(X) = \nabla f(X_0) + H_{f(x)}(X - X_0)$

令 $\nabla f(X) = 0$ 可得: $X = X_0 - H^{-1}_{f(x_0)} \nabla f(X_0)$

高斯牛顿法: 利用 $F(X) = \frac{1}{2}\sum_{k=1}^{m} r_k^2(x)$ 的特殊性. (m为数据点个数, n为未知数个数)

其中 $X = [O_x, O_y, O_z, S_x, S_y, S_z]^T$

$r_k(x) = y_k - f(x_k) = 1 - [(x_k - O_x)^2 S_x^2 + (y - O_y)^2 S_y^2 + (z - O_z)^2 S_z^2]$

计算: $\nabla F(x) = \nabla \frac{1}{2}\sum_{k=1}^{m} r_k^2(x) = \frac{1}{2}\sum_{k=1}^{m} \nabla r_k^2(x) = \frac{1}{2}\sum_{k=1}^{m} [2 r_k(x) \nabla r_k(x)] = \sum_{k=1}^{m} r_k(x) \nabla r_k(x)$

$= r_1 \nabla r_1(x) + \cdots + r_m \nabla r_m(x)$

$= (\nabla r_1(x) \ \nabla r_2(x) \ \nabla r_3(x) \ \cdots \ \nabla r_m(x)) \begin{pmatrix} r_1(x) \\ r_2(x) \\ \vdots \\ r_m(x) \end{pmatrix}$

$= J_r^T r$

其中, $J_r = \begin{pmatrix} \nabla r_1^T(x) \\ \nabla r_2^T(x) \\ \vdots \\ \nabla r_m^T(x) \end{pmatrix} = \begin{bmatrix} \frac{\partial r_1}{\partial x_1} & \frac{\partial r_1}{\partial x_2} & \cdots & \frac{\partial r_1}{\partial x_n} \\ \frac{\partial r_2}{\partial x_1} & \frac{\partial r_2}{\partial x_2} & \cdots & \frac{\partial r_2}{\partial x_n} \\ \vdots & \vdots & & \vdots \\ \frac{\partial r_m}{\partial x_1} & \frac{\partial r_m}{\partial x_2} & \cdots & \frac{\partial r_m}{\partial x_n} \end{bmatrix}_{m \times n}$ $r = \begin{pmatrix} r_1(x) \\ r_2(x) \\ \vdots \\ r_m(x) \end{pmatrix}_{m \times 1}$

计算: $H(x) = \nabla[\nabla F(x)] = \nabla\left[\sum_{k=1}^{m} r_k(x) \nabla r_k^T(x)\right] = \sum_{k=1}^{m} \nabla[r_k(x) \nabla r_k^T(x)]$.

$= \sum_{k=1}^{m} [\nabla r_k(x) \nabla r_k^T(x) + r_k(x) \nabla[\nabla r_k^T(x)]]$ 在高斯牛顿法中, 假设第二项小, 舍

$= \sum_{k=1}^{m} \nabla r_k(x) \nabla r_k^T(x) + \sum_{k=1}^{m} r_k(x) \nabla[\nabla r_k^T(x)]$

看第一项, 为 $n \times 1 \times [\,]_{1 \times n}$ 得 $n \times n$ 矩阵, m个 $[\,]_{n \times n}$ 相加.

观察 $a_{ij} = \sum_{k=1}^{m} \frac{\partial r_k}{\partial x_i} \times \frac{\partial r_k}{\partial x_j} = \left[\frac{\partial r_1}{\partial x_i} \ \frac{\partial r_2}{\partial x_i} \ \cdots \ \frac{\partial r_k}{\partial x_i}\right] \begin{bmatrix} \frac{\partial r_1}{\partial x_j} \\ \vdots \\ \frac{\partial r_k}{\partial x_j} \end{bmatrix}$

$\therefore H(x) \approx \begin{bmatrix} \frac{\partial r_1}{\partial x_1} & \frac{\partial r_2}{\partial x_1} & \cdots & \frac{\partial r_m}{\partial x_1} \\ \frac{\partial r_1}{\partial x_2} & \frac{\partial r_2}{\partial x_2} & \cdots & \frac{\partial r_m}{\partial x_2} \\ \vdots & \vdots & & \vdots \\ \frac{\partial r_1}{\partial x_n} & \frac{\partial r_2}{\partial x_n} & \cdots & \frac{\partial r_m}{\partial x_n} \end{bmatrix}_{n \times m} \times \begin{bmatrix} \frac{\partial r_1}{\partial x_1} & \frac{\partial r_1}{\partial x_2} & \cdots & \frac{\partial r_1}{\partial x_n} \\ \frac{\partial r_2}{\partial x_1} & \frac{\partial r_2}{\partial x_2} & \cdots & \frac{\partial r_2}{\partial x_n} \\ \vdots & \vdots & & \vdots \\ \frac{\partial r_m}{\partial x_1} & \frac{\partial r_m}{\partial x_2} & \cdots & \frac{\partial r_m}{\partial x_n} \end{bmatrix}_{m \times n} = J_r^T J_r$

$X = X_0 - H^{-1}(x_0) \nabla F(x_0) = X_0 - [J_r^T(x_0) J_r(x_0)]^{-1} J_{r(x)}^T r(x_0)$.

针对加速度计误差：

$$J_r^T=\begin{bmatrix} 2S_x^2O_x & 2S_x^2O_x & \cdots & 2S_x^2O_x \\ 2S_y^2O_y & 2S_y^2O_y & & 2S_y^2O_y \\ 2S_z^2O_z & 2S_z^2O_z & & 2S_z^2O_z \\ -2S_x(x_1-O_x)^2 & -2(x_2-O_x)^2S_x & & -2(x_m-O_x)S_x \\ -2(y_1-O_y)^2S_y & -2(y_2-O_y)^2S_y & & -2(y_m-O_y)^2S_y \\ -2(z_1-O_z)^2S_z & -2(z_2-O_z)^2S_z & & -2(z_m-O_z)^2S_z \end{bmatrix}_{6\times m}$$

迭代后得到 $X=[O_x\ O_y\ O_z\ S_x\ S_y\ S_z]^T$

则可得到消除误差的 $a=(a_x, a_y, a_z)$ 与 qqq^* 之间理论相等。

$$r(x)=qqq^*-a$$

$$=\begin{bmatrix} 2ac+2bd \\ 2cd-2ab \\ 1-2b^2-2c^2 \end{bmatrix}-\begin{bmatrix} a_x \\ a_y \\ a_z \end{bmatrix}$$

$$J_r=\begin{bmatrix} 2c & 2d & 2a & 2b \\ -2b & -2a & 2d & 2c \\ 0 & -4b & -4c & 0 \end{bmatrix}$$

$X=[a,b,c,d]^T$

$$X=X_0-\left[J_{r(X_0)}^T J_{r(X_0)}\right]^{-1} J_{r(X_0)}^T r(X_0)$$

$X=\frac{X}{\|X\|}$ 确保 X 为单位向量

重复迭代直至收敛。